检索增强生成综述

摘要：检索增强生成（Retrieval-Augmented Generation，RAG）通过在生成阶段引入外部知识库，有效缓解了大语言模型的幻觉问题，并显著提升了知识密集型任务的可信度。

一、引言。大语言模型虽然具备强大的生成能力，但其训练数据存在时间截止与覆盖不足的问题。当用户提出超出模型知识范围的问题时，模型容易产生看似合理却与事实不符的回答。

二、核心流程。RAG 的基本流程包括：文档加载与切分、向量化、相似度检索、提示拼接与生成。其中向量维度与嵌入模型必须保持一致，否则插入向量库时会直接报错。

三、评价指标。常用的评估维度包括忠实度（Faithfulness）、答案相关性（Answer Relevancy）与上下文精度（Context Precision）。

四、主流方案对比

方案	特点
朴素 RAG	检索后直接拼接上下文，实现简单
混合检索	向量 + BM25 关键字，兼顾语义与精确匹配
重排序	对召回结果二次排序，提升上下文精度